

규칙 기반 조건 추출과 속성 재랭킹을 결합한 한국어 자연어 음식 메뉴 추천

Menu-recommend-algorithmn 프로젝트 기술 보고서 · 2026-09-26

초록

"비도 오고 쌀쌀한데 얼큰한 국물 먹고 싶어"처럼 자유롭게 쓴 한국어 문장을 받아 음식 메뉴 상위 $K = 5$ 개를 추천하는 시스템을 제안한다. 공공데이터포털의 식품 영양성분 데이터 19,617행을 정제해 메뉴 5,219건을 만들고, 대규모 언어 모델로 매운맛, 국물, 제공온도, 조리법, 기름짐, 든든함의 6개 속성 라벨을 붙였으며, 추천 후보는 업체명이 없는 공공 데이터 1,088건으로 한정했다. 제안 방법은 규칙 43개로 질의를 필수 조건, 선호 조건, 메뉴 언급, 맥락으로 분해하고, multilingual-e5-base 밀집 검색 결과를 필수 조건으로 거른 뒤 유사도, 선호 일치율, 언급 가점의 선형 결합으로 재랭킹하고 메뉴군 상한으로 다양성을 제어한다. 점수 척도를 분석한 결과, 후보 100개 안에서 유사도 향의 폭은 평균 0.014로 선호 조건 한 단계 (최소 0.1)보다 한 자릿수 작아 재랭킹은 사실상 선호 일치율 우선의 사전식 정렬로 동작하며, 이 관계에서 가점 크기의 상한 조건을 유도했다. 질의 36개와 승인된 적합도 판정 906건(교차 판정 가중 $\kappa_w = 0.919$)으로 평가한 결과, 임베딩만 쓴 기준선의 nDCG@5 0.509가 0.878(P@5 0.789, MRR 0.938)로 올랐고 향상 폭 +0.369의 95% 부트스트랩 신뢰구간은 [+0.244, +0.495]였다. 향상은 부정 표현 질의에서 가장 컸고(0.173에서 0.893), 기성 cross-encoder 재정렬(bge-reranker-v2-m3)은 조건 로직 위에 더해도 성능을 올리지 못했다. 다만 평가 질의를 보면서 시스템을 조정했으므로 처음 보는 질의에서는 성능이 이보다 낮을 가능성이 크다. 서비스에 붙인 뒤에는 사용자 반응을 질의 단어와 메뉴 조합별 가점으로 즉시 반영하고, 승인 판정 295쌍으로 인코더를 미세조정했다. 학습용 질의의 정답 회수율@10은 0.405에서 0.518로 올랐지만 학습에 쓰지 않은 질의 10개에서는 0.439에서 0.405로 내려가 일반화되지 않았고, 미판정을 0점으로 두는 nDCG의 큰 하락(0.932에서 0.740)은 대부분 폴링 편향이었다. 그래서 condensed nDCG와 회수율로 교체 기준을 세우고 기본 모델을 유지했다.

주제어: 자연어 추천, 조건 기반 검색, 밀집 검색, 재랭킹, 부정 표현, 폴링 평가, 사용자 피드백, 미세조정

1. 서론

1.1 배경

메뉴를 고를 때 사람들은 "안 맵고 국물 있는 면"처럼 여러 속성 조건을 섞어 말하고, "튀김 말고", "매운 건 싫어" 같은 부정 표현이나 "비 오는 날" 같은 맥락도 자주 쓴다. 이런 요청은 속성에 대한 제약과 선호의 결합이므로 협업 필터링처럼 사용 이력에 기대는 방식보다는 질의 문장 자체를 해석하는 방식이 맞다.

문장 임베딩 기반 밀집 검색은 의미적으로 가까운 문서를 잘 찾지만 논리적 조건을 지키는 데는 약하다. 대조 학습으로 훈련한 임베딩은 "맵지 않은 음식"과 "매운 음식"이 같은 주제어를 공유하므로 두 문장을 가깝게 두며, 실제로 본 연구의 평가에서 부정 표현 질의에 대한 임베딩 단독 검색의 nDCG@5는 0.173에 그쳤다(7.2절).

1.2 연구 질문

- **RQ1** 규칙 기반 조건 추출과 속성 필터·재랭킹은 밀집 검색 대비 얼마나 기여하는가

- **RQ2** 유사도, 선호, 가점을 선형 결합할 때 각 항의 척도는 순위에 어떤 영향을 주며, 가중치는 어떤 조건을 만족해야 하는가
- **RQ3** 범용 cross-encoder 재정렬이나 대분류 우선 추천 같은 대안은 이 도메인에서 효과가 있는가
- **RQ4** 모델 판정에 기반한 평가 세트는 얼마나 신뢰할 수 있으며, 결과 해석의 한계는 무엇인가
- **RQ5** 사용자 피드백과 판정 데이터로 인코더를 미세조정하면 처음 보는 질의에서도 나아지는가, 기존 판정 풀로 이를 공정하게 잴 수 있는가

1.3 기여

1. 공공 영양성분 데이터를 식사 메뉴 단위로 정제하고 6개 속성 라벨을 붙인 한국어 메뉴 후보 집합 구축
2. 필수와 선호를 구분하고 거부어에 따른 극성 반전, 조건 병합, 모순 검출을 포함하는 조건 추출 규칙의 형식화
3. 재랭킹 점수 척도 분석과 이를 바탕으로 한 가점 크기의 상한 조건 유도, 실험으로 확인
4. 여러 설정의 상위 결과를 합치고 두 모델이 교차 판정한 풀링 판정 세트 구축과 일치도 보고
5. cross-encoder 재정렬과 대분류 우선 추천이 이 데이터에서 효과가 없는 이유를 정량적으로 제시
6. 사용자 피드백 가점과 판정 기반 미세조정을 서비스에 붙이고, 풀링 편향을 피하는 교체 기준으로 미세조정 효과를 검증

2. 관련 연구

밀집 검색 Sentence-BERT(Reimers & Gurevych, 2019) 이후 문장 임베딩의 코사인 유사도로 검색하는 bi-encoder 방식이 널리 쓰인다. E5(Wang et al., 2024)는 대규모 약지도 쌍으로 대조 학습한 텍스트 임베딩 모델로 질의와 문서에 각각 `query: , passage:` 접두어를 붙여 비대칭 검색을 하며, 본 연구는 다국어판 multilingual-e5-base를 쓴다.

재정렬 cross-encoder는 질의와 문서를 한 입력으로 넣어 토큰 수준 상호작용을 모델링하므로 보통 bi-encoder보다 정확하며, 검색 상위 후보만 다시 매기는 2단계 구조로 쓰인다(Nogueira & Cho, 2019). BGE M3(Chen et al., 2024) 계열 재정렬 모델은 다국어를 지원한다.

조건 기반 추천 지식 기반 또는 제약 기반 추천은 사용자가 명시한 속성 제약을 만족하는 항목을 고르며, 제약을 만족하는 항목이 없을 때 어떤 제약을 완화할지가 핵심 문제로 다뤄진다(Felfernig & Burke, 2008). 본 연구는 필수 조건은 완화하지 않고 대신 검색 범위를 넓히며, 선호 조건은 점수로만 반영하는 절충을 택했다.

평가 순위 지표로 누적 이득 기반의 nDCG(Järvelin & Kekäläinen, 2002), P@K, MRR을 쓴다. 전체 문서를 판정할 수 없을 때는 여러 시스템의 상위 결과만 판정하는 TREC 방식의 풀링을 쓰며, 풀에 없는 문서를 부적합으로 보는 가정이 새로운 시스템에 불리하게 작용할 수 있다는 편향이 알려져 있다(Buckley & Voorhees, 2004). 판정자 간 일치도는 Cohen의 κ 로 보고한다(Cohen, 1960).

3. 문제 정의

후보 메뉴 집합을 $\mathcal{D}(|\mathcal{D}| = 1,088)$, 속성 집합을 $\mathcal{A}(|\mathcal{A}| = 6)$, 속성 a 의 값 영역을 V_a 라 하고, 라벨을 정할 수 없는 경우를 $\perp$ (미확인)로 둔다. 각 메뉴 d 는 라벨 벡터

$$\ell(d) = (\ell_a(d))_{a \in \mathcal{A}}, \quad \ell_a(d) \in V_a \cup \{\perp\}$$

와 메뉴명, 대표식품명, 식품대분류명으로 이루어진 이름 정보 $n(d)$ 를 가진다. 질의 q 가 주어지면 시스템은 순서가 있는 목록 $R_q = (d_1, \dots, d_k), k \leq K$ 를 반환하며, 목표는 적합도 판정 $g(q, d) \in \{0, 1, 2\}$ 에 대한 순위 지표를 최대화하는 것이다.

조건 추출기 π 는 질의를 다섯 요소로 분해한다.

$$\pi(q) = (H, S, M, X, C)$$

- $H = \{(a, A_a^H)\}$: 필수 조건, $A_a^H \subseteq V_a$ 는 허용값 집합
- $S = \{(a, A_a^S)\}$: 선호 조건
- M : 사용자가 언급한 메뉴 용어 집합 (예: "샌드위치")
- X : 제외한 메뉴 용어 집합 (예: "피자 말고"의 "피자")
- C : 맥락이 연상한 메뉴 용어 집합 (예: "비 오는 날"의 "칼국수")

메뉴 d 가 용어 t 를 가리키는지는 부분 문자열이 아닌 완전 일치로 판정한다.

$$\mu(d, t) = 1 [t = \text{대표식품명}(d) \vee t \in \text{tok}(\text{메뉴명}(d)) \vee t \in \text{tok}(\text{대분류}(d))]$$

여기서 tok은 공백 기준 어절 집합이며, 부분 문자열 대조를 쓰지 않는 이유는 "무조건"의 "무"가 "무국"과 맞는 식의 오탐을 막기 위해서다.

4. 데이터

4.1 원본과 정제

공공데이터포털의 식품 영양성분 데이터(food_nutrition.csv, 19,617행, 50열)를 사용했다.

단계	건수	처리
원본	19,617	식품 영양성분 DB
정제	18,998	이름 정리, 중량 분리, 컬럼 선별
식사 메뉴	8,032	식품대분류로 식사를 고르고 반찬·디저트·음료 제외, 빵 및 과자류 중 피자·버거·샌드위치 등은 식사로 포함
라벨링 단위	5,219	같은 메뉴의 중복 행 통합
공공 데이터 (업체명 없음)	1,123	프랜차이즈 메뉴 제외
추천 후보 $\mathcal{D}$	1,088	쌀밥·잡곡밥 같은 맨밥 제외

후보는 식품대분류 12개에 퍼져 있으며 국 및 탕류(210), 찌개 및 전골류(153), 밥류(151), 면 및 만두류(129), 구이류(98), 볶음류(88) 순으로 많다. 프랜차이즈를 제외한 이유는 같은 메뉴의 브랜드별 변형이 상위를 독점하는 문제와 데이터 출처의 일관성 때문이다.

4.2 속성 라벨

속성 a	값 영역 V_a	$ V_a $
매운맛	없음, 약함, 보통, 강함	4
국물	국물요리, 국물약간, 국물없음	3
제공온도	뜨거움, 따뜻함, 상온, 차가움	4
조리법	끓임, 볶음, 구이, 튀김, 찜, 조림, 부침, 오븐, 비조리, 혼합	10
기름짐	낮음, 보통, 높음	3
튼튼함	가벼움, 보통, 튼튼함	3

라벨은 이름 정보 $n(d)$ 만 입력으로 대화형 언어 모델 세션에서 매겼고(유료 API 미사용), 스키마 밖의 값이나 형식 오류는 검증 단계에서 걸러 다시 매겼다. 원본의 온도 표기(HOT, ICED)가 있으면 그와 양립하는 제공온도만 허용했다.

그림 1. 추천 후보 1,088건의 속성별 '미확인' 라벨 비율




그림 1에서 속성별 $\perp$ 비율은 튼튼함이 23.3%로 가장 높고 매운맛 5.1%, 나머지는 1% 미만이다. 5.3절의 필터는 $\perp$ 을 충족으로 보지 않으므로 튼튼함이 필수 조건이 되면 후보 넷 중 하나가 무조건 빠진다. 이 밖에 계열(한식, 중식, 일식, 양식, 동남아, 분식)과 안주 여부를 메뉴명 키워드 규칙으로 추정하고 공공 데이터 1,123건은 대화 모델 라벨로 보정했다. 라벨은 모두 모델 추정이며, 사람이 표본을 검토한 정확도는 아직 측정하지 않았다(10.3절).

5. 방법

5.1 전체 구조

```
flowchart LR
    Q[질의 q] --> P[조건 추출 π]
    Q --> E[질의 임베딩 f]
    E --> R[코사인 검색 상위 k]
```

P $\rightarrow$ F [필수 조건·메뉴 제외 필터]
 R $\rightarrow$ F
 F $\rightarrow$ S [재랭킹 score]
 P $\rightarrow$ S
 S $\rightarrow$ D [중복 제거·메뉴군 상한]
 D $\rightarrow$ K [Top-K와 근거]
 D $\rightarrow$. 부족하면 k를 2배 $\rightarrow$ R

5.2 조건 추출

규칙 집합 $\mathcal{R}$ 은 정규식 43개로 이루어지며, 각 규칙 r 은 패턴, 종류 $\tau(r) \in \{\text{hard}, \text{soft}, \text{context}, \text{unhandled}\}$, 조건 목록 $\{(a, A)\}$ 를 가진다. 규칙은 우선순위 순서로 적용되고, 먼저 매칭된 구간과 겹치는 매칭은 버린다.

종류	개수	예	처리
hard	7	"맵지 않은", "국물 없는", "튀김 말고"	H 에 추가
soft	26	"얼큰한", "따뜻한", "가볍게"	S 에 추가
context	6	"비 오는 날", "추운 날"	연상 용어를 C 에 추가
unhandled	4	이중 부정, "단짠"."상큼" 같은 스키마 밖 맛	조건 없이 기록만

극성 반전 soft 규칙의 매칭 직후에 거부어 패턴 ρ ("싫", "빠", "말고", "못 먹", "아닌", "별로" 등)가 이어지면 조건을 여집합의 필수 조건으로 바꾼다.

$$(a, A) \in S \text{ 이고 } \rho \text{ 가 뒤따르면 } (a, V_a \setminus A) \in H$$

예를 들어 "매운 건 싫어"의 "매운"은 선호 (매운 맛, {보통, 강함})이지만 뒤의 "싫"에 의해 필수 (매운 맛, {없음, 약함})이 된다. 또한 "꼭", "반드시", "무조건"이 매칭 바로 앞에 있으면 선호를 같은 허용값의 필수로 올린다.

필수 조건 병합과 모순 같은 속성의 필수 조건 $A_a^{(1)}, \dots, A_a^{(m)}$ 는 교집합으로 합친다.

$$A_a^H = \bigcap_{i=1}^m A_a^{(i)}, \quad A_a^H = \emptyset \Rightarrow \text{모순}$$

모순이면 결과를 내지 않고 사유를 반환한다(예: "맵지 않은 매운 음식").

선호 조건 병합 같은 속성의 선호는 교집합이 비어 있지 않으면 교집합으로 합치고, 비어 있으면 서로 상충하는 선호로 보아 둘 다 버린다("시원하고 얼큰한"의 제공온도). 그 뒤 같은 속성의 필수 조건이 있으면 선호를 필수 허용값 안으로 좁힌다.

$$A_a^S \leftarrow A_a^S \cap A_a^H, \quad A_a^S \cap A_a^H = \emptyset \Rightarrow \text{모순}$$

메뉴 용어 메뉴 종류 사전과 일치하는 어절은 조건이 아닌 M 으로, "A 말고" 형태의 A는 X 로 기록한다. "밥"을 단독으로 말하면 밥류 언급과 한식 선호로 해석한다.

5.3 검색과 필터

질의와 메뉴 텍스트를 같은 인코더로 임베딩하며, 메뉴 텍스트는 두 가지로 구성해 비교했다.

- **텍스트 A:** 메뉴명, 대표식품명, 식품대분류명을 이어 붙인 문자열
- **텍스트 B:** 텍스트 A 뒤에 $\perp$ 이 아닌 속성 토큰을 붙인 문자열 (예: "소고기스튜 찜류 매운맛 없음 국물약간 제공온도 뜨거움 ...")

인코더는 mean pooling 뒤 L2 정규화를 하므로 코사인 유사도는 내적과 같다.

$$s(q, d) = \langle f(\text{query: } q), f(\text{passage: text}(d)) \rangle, \quad \|f(\cdot)\|_2 = 1$$

상위 k 개 후보 집합을 $\mathcal{C}_k(q)$ 라 하면 필터를 통과한 후보는

$$\mathcal{F}_k(q) = \left\{ d \in \mathcal{C}_k(q) : \forall (a, A) \in H, \ell_a(d) \in A \wedge \forall t \in X, \mu(d, t) = 0 \right\}$$

이며, $\perp \notin A$ 이므로 라벨이 $\perp$ 인 메뉴는 그 속성의 필수 조건을 충족하지 못한다. 저장된 임베딩은 모델 리비전, 접두어, pooling, 원본 파일 해시를 기록한 manifest와 대조해 일치할 때만 불러온다.

5.4 재랭킹 점수

선호 일치율과 가점은 다음과 같다.

$$p(q, d) = \begin{cases} \frac{1}{|S|} \sum_{(a,A) \in S} 1[\ell_a(d) \in A] & |S| > 0 \\ 0 & |S| = 0 \end{cases}$$

$$b(q, d) = \max \left(w_m \cdot \max_{t \in M} \mu(d, t), w_c \cdot \max_{t \in C} \mu(d, t) \right)$$

최종 점수는 세 항의 선형 결합이다.

$$\text{score}(q, d) = w_s \cdot s(q, d) + w_p \cdot p(q, d) + b(q, d)$$


기본값은 $w_s = 0.7, w_p = 0.3, w_m = 0.3, w_c = 0.05$ 이며, 동점은 유사도 내림차순, 메뉴 ID 오름차순으로 결정적으로 갱신. p 에서 $\perp$ 을 일치로 세지 않으므로 라벨이 빈 메뉴는 선호 조건에서도 불리하고, 두 가점을 더하지 않고 큰 쪽만 쓰는 이유는 언급 메뉴와 연상 메뉴가 겹칠 때 이중으로 가산되는 것을 막기 위해서다.

5.5 점수 척도 분석

유사도 향이 실제로 순위에 주는 영향을 보려고 후보 $\mathcal{C}_{100}(q)$ 안의 유사도 폭을 측정했다.

$$\Delta_s(q) = \max_{d \in \mathcal{C}_{100}(q)} s(q, d) - \min_{d \in \mathcal{C}_{100}(q)} s(q, d)$$

그림 2. 유사도 항의 점수 폭과 선호·가점 항의 크기 비교



평가 질의 36개에서 1위 유사도의 평균은 0.844, Δ_s 의 평균은 0.0196, 최댓값은 0.052였다. 그림 2처럼 유사도 항의 폭 $w_s \Delta_s$ 는 평균 0.014, 최대 0.036으로, 선호 조건 하나의 일치 여부가 만드는 점수 차이 $w_p/|S|$ (조건 1개면 0.3, 2개면 0.15, 3개면 0.1)보다 한 자릿수 작다. 이로부터 다음 성질이 나온다.

명제 1 (선호 우선 정렬) 같은 가점을 받는 두 후보 $d, d' \in \mathcal{F}_k(q)$ 에 대해 $w_s \Delta_s(q) < w_p/|S|$ 이면

$$p(q, d) > p(q, d') \Rightarrow \text{score}(q, d) > \text{score}(q, d')$$

증명 p 는 $1/|S|$ 단위로만 달라지므로 $p(q, d) - p(q, d') \geq 1/|S|$ 이고, $\text{score}(q, d) - \text{score}(q, d') \geq w_p/|S| - w_s |s(q, d) - s(q, d')| \geq w_p/|S| - w_s \Delta_s(q) > 0$ 이다. $\square$

즉 재랭킹은 (가점, 선호 일치율, 유사도) 순의 사전식 정렬에 가깝게 동작하며, 유사도는 같은 선호 수준 안에서의 순서만 정한다. 이 성질에서 가점 크기에 대한 두 조건을 얻는다.

따름정리 1 (연상 가점의 상한) 연상 가점이 명시한 선호 조건 하나를 뒤집지 않으려면

$$w_c < \frac{w_p}{|S|_{\max}} - w_s \Delta_s$$

이어야 한다. 평가 질의의 선호 조건은 최대 3개이므로 $w_c < 0.1 - 0.036 = 0.064$ 가 필요하며, 이전 설정 $w_c = 0.15$ 는 이를 위반한다. 실제로 "비 오는 날 얼큰한 국물 먹고 싶어"는 $S = \{\text{매운맛, 제공 온도, 국물}\}$ 로 한 단계가 0.1인데, 연상된 전(부침개)이 국물 조건 하나를 어겨 $p = 2/3$ 이면서도 가점 0.15를 받아 $p = 1$ 인 국물 요리를 앞질렀다. 채택한 $w_c = 0.05$ 는 이 조건을 만족하면서 $w_s \Delta_s$ 의 평균(0.014)보다는 커서, 선호 수준이 같은 후보들 사이에서는 연상 메뉴를 앞에 둔다.

따름정리 2 (언급 가점의 의미) $w_m = w_p$ 이면 언급한 메뉴는 모든 선호 조건을 만족한 것과 같은 점수를 받는다. "샌드위치 가볍게"는 $S = \{\text{든든함}\}$ 하나라 $w_p/|S| = 0.3$ 인데, 이전 설정 $w_m = 0.15$ 에서는 든든함이 보통 인 샌드위치 (0.15)가 가벼운 인 죽(0.3)을 이기지 못했다. $w_m = 0.3$ 에서는 둘이 같은 수준이 되어 유사도가 높은 샌드위치가 앞선다. 반대로 $w_m > w_p$ 이면 언급 메뉴가 선호 조건을 전부 어겨도 올라오므로, "김밥이랑 국물"처럼 언급 메뉴가 주인공이 아닌 질의에서 손해가 커진다(7.4절).

5.6 중복 제거와 다양성 제어

두 메뉴 이름에서 괄호, 공백, 구두점, 사이즈·도우 표기를 지운 정규화 키가 같으면 같은 메뉴의 변형으로 본다. 업체명이 없는 공공 데이터는 어절 단위 접두어 관계일 때만 변형으로 보며("두부찌개"와 "두부찌개 바지락"은 변형, "순대"와 "순대볶음 백순대"는 다른 메뉴), 메뉴군 $\gamma(d)$ 는 대표식품명의 마지막 어절이다("붕어 매운탕"과 "아귀 매운탕"은 같은 "매운탕" 메뉴군).

알고리즘 1 상위 K 개 선택

입력: 점수순으로 정렬된 후보 목록 L , 메뉴군 상한 $c = 2$, 상한 면제 메뉴군 집합 $E = \{\gamma(d) : \exists t \in M \cup C, \mu(d, t) = 1\}$

1. $R \leftarrow ()$, 모든 메뉴군의 선택 횟수 $n_\gamma \leftarrow 0$
2. L 의 각 후보 d 를 순서대로 보며 $|R| = K$ 가 되면 멈춤
 1. R 안에 d 의 변형이 있으면 건너됨 (사유: 중복)
 2. $\gamma(d) \notin E$ 이고 $n_{\gamma(d)} \geq c$ 이면 건너됨 (사유: 메뉴군 상한)
 3. 아니면 d 를 R 에 추가하고 $n_{\gamma(d)} \leftarrow n_{\gamma(d)} + 1$
3. R 과 건너뛴 후보의 사유를 반환

5.7 검색 범위 확장

필수 조건을 통과한 후보가 부족하면 조건을 완화하는 대신 검색 범위를 넓힌다.

알고리즘 2 검색 범위 확장

1. $k \leftarrow 100$
2. $R \leftarrow \text{Select}(\text{sort}_{\text{score}} \mathcal{F}_k(q))$ (Select는 알고리즘 1)
3. $|R| < K$ 이고 $k < |\mathcal{D}|$ 이면 $k \leftarrow \min(2k, |\mathcal{D}|)$ 로 두고 2로 돌아감
4. $|S| > 0$ 이고 $\sum_{d \in R} 1[p(q, d) = 1] < K$ 이고 $k < 400$ 이면 $k \leftarrow \min(2k, 400)$ 로 두고 2로 돌아감
5. R 을 반환하되 $|R| < K$ 이면 상태를 shortage 로 표시하고 사유를 기록

3단계는 전체 후보까지, 4단계는 선호를 모두 만족하는 후보를 찾기 위해 400개까지만 넓힌다. 필수 조건은 어떤 경우에도 완화하지 않으므로 반환 목록은 항상 H 를 만족하며, 이는 조건 준수를 순위 품질보다 우선하는 설계 선택이다.

6. 실험 설정

6.1 질의 세트

평가 질의 40개를 유형별로 만들었고, 공공 데이터에 적합(2점) 메뉴가 0~2개뿐인 4개("치킨 먹고 싶어", "튀김 말고 구운 치킨", "피자 먹고 싶는데 느끼하지 않은 걸로", "다이어트 중이라 가벼운 샐러드")를 빼고 36개로 평가했다. 빈 입력과 모순 질의 2개("맵지 않은 매운 음식", "국물 없는 국물 요리")는 0건 반환이 정답인 별도 사례로 확인했다.

유형	수	예
기본	12	"비 오는 날 얼큰한 국물 먹고 싶어", "든든한 밥 한 끼"
복합 조건	9	"안 맵고 국물 있는 면", "짬 요리 든든하게"
부정 표현	6	"튀김 아닌 걸로 가볍게", "뜨겁지 않은 음식"
맥락	4	"추운 날 뜨끈한 국밥", "야식으로 가벼운 거"
메뉴 언급	4	"샌드위치 가볍게", "피자 말고 버거"
판정 미확정	1	"안 매운 건 싫어"


조건 추출기는 36개 중 32개에서 선호나 필수 조건을 하나 이상 뽑았으며(필수 포함 12개, 메뉴 언급 11개, 맥락 3개), 조건을 하나도 뽑지 못한 질의는 "단짠단짠한 음식", "비 오는 날 전 부쳐 먹고 싶다", "안 매운 건 싫어", "피자 말고 버거"의 4개로 이 중 뒤의 두 질의는 메뉴 언급이나 메뉴 제외는 인식했다.

6.2 판정 세트

판정 세트는 다음 네 단계로 구축했다.

1. **풀링**: 텍스트 A/B, 단계별 구성, 메뉴군 상한과 가점 변형, cross-encoder 변형의 상위 5개를 합쳐 (질의, 메뉴) 판정 풀 구성
2. **1차 판정**: 모델이 질의별 판정기준에 따라 2(적합), 1(부분 적합), 0(부적합)으로 판정 (예: "2: 매콤한 뜨거운 국물 요리 / 1: 국물 요리지만 안 매움 / 0: 그 외")
3. **교차 판정**: 다른 모델(Sonnet)이 기존 판정을 보지 않고 공공 데이터 971행을 다시 판정
4. **재판정과 승인**: 모호한 판정기준을 보강해 불일치 행을 다시 판정하고 질의 단위로 승인 상태로 반영

그림 3. 판정 교차 검증 (공공 데이터 971행)



두 판정의 일치도는 혼동 행렬 $O = (o_{ij})$ 와 주변 분포로 만든 기대 행렬 $E = (e_{ij})$, $e_{ij} = o_{i \cdot} o_{\cdot j} / N$ 으로 계산했다.

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \quad p_o = \frac{1}{N} \sum_i o_{ii}, \quad p_e = \frac{1}{N^2} \sum_i o_{i \cdot} o_{\cdot i}$$

$$\kappa_w = 1 - \frac{\sum_{i,j} w_{ij} o_{ij}}{\sum_{i,j} w_{ij} e_{ij}}, \quad w_{ij} = (i - j)^2$$

그림 3에서 일치율은 89.4%(868/971), 단순 $\kappa = 0.836$, 이차 가중 $\kappa_w = 0.919$ 이다. 불일치 103건 중 99건은 2와 1 또는 1과 0 사이의 한 칸 차이였고 0과 2로 정반대인 경우는 4건이었다. 다만 두 판정자가 같은 계열의 모델이라 높은 일치도가 곧 정확성을 뜻하지는 않으며, 최종 승인 판정은 906건(적합 440, 부분 적합 225, 부적합 241)이다.

6.3 지표

질의 q 에 대한 반환 목록의 i 번째 항목 적합도를 g_i , 그 질의에서 판정된 모든 적합도의 다중집합을 J_q 라 한다. 판정 풀에 없는 항목은 $g_i = 0$ 으로 두고 그 비율을 미판정 비율로 따로 보고한다.

$$P@K = \frac{1}{K} \sum_{i=1}^K 1[g_i \geq 2]$$

$$DCG@K = \sum_{i=1}^K \frac{2^{g_i} - 1}{\log_2(i + 1)}, \quad nDCG@K = \frac{DCG@K}{IDCG@K}$$

IDCG@K는 J_q 를 내림차순으로 정렬한 이상적 목록의 DCG이며, 반환 수가 K 보다 적어도 분모는 그대로 둔다.

$$RR = \begin{cases} 1/\min\{i : g_i \geq 2\} & \exists i, g_i \geq 2 \\ 0 & \text{그 외} \end{cases}, \quad MRR = \frac{1}{|Q|} \sum_{q \in Q} RR_q$$

6.4 통계 검정

두 설정 A, B의 차이는 질의별 차이 $\delta_q = m_B(q) - m_A(q)$ 로 대응 부트스트랩을 한다. 질의 집합 Q 에서 크기 $|Q|$ 의 표본을 복원 추출해 평균 $\bar{\delta}^{*(b)}$ 를 $B = 2,000$ 회 구하고, 이를 정렬한 순서 통계량으로

$$CI_{95\%} = \left[\bar{\delta}_{(\lfloor 0.025B \rfloor)}^*, \bar{\delta}_{(\lfloor 0.975B \rfloor)}^* \right]$$

를 쓴다. 구간이 0을 포함하면 우연 범위로 본다.


6.5 하이퍼파라미터와 환경

항목	값
인코더	intfloat/multilingual-e5-base (768차원, mean pooling, L2 정규화, 최대 512 토큰)
초기 검색 수 k	100 (필수 부족 시 전체까지, 선호 부족 시 400까지 2배씩)
반환 수 K	5
가중치 w_s, w_p, w_m, w_c	0.7, 0.3, 0.3, 0.05
메뉴군 상한 c	2
부트스트랩	$B = 2,000$, seed 0
환경	Apple Silicon 노트북, Python 3.12, sentence-transformers 6.1, PyTorch 2.14

7. 결과

7.1 단계별 기여 (RQ1)

그림 4. 파이프라인 단계별 성능 (승인 판정, 질의 36개, 텍스트 B)



설정	P@5	nDCG@5	MRR	미판정	최종 대비 nDCG 차이 [95% CI]
임베딩만	0.433	0.509	0.537	2.8%	-0.369 [-0.495, -0.244]
+ 조건 필터	0.500	0.606	0.620	2.8%	-0.272 [-0.393, -0.156]
+ 선호 재랭킹, 중복 제어 ($w_m = w_c = 0.15$)	0.767	0.847	0.889	0%	-0.031 [-0.096, +0.011]
최종 ($w_m = 0.3, w_c = 0.05$)	0.789	0.878	0.938	0%	0
최종, 텍스트 A	0.794	0.858	0.870	0%	

그림 4와 표에서 조건 필터가 nDCG를 +0.097, 선호 재랭킹과 중복 제어가 +0.241 올려 가장 큰 기여는 선호 재랭킹이다. 이는 5.5절의 분석과 맞는데, 필터는 조건을 어기는 후보를 지울 뿐 남은 후보의 순서는 유사도에 맡기는 반면 재랭킹은 선호 일치율로 순서 자체를 다시 정한다. 속성 토크를 넣은 텍스트 B는 텍스트 A보다 nDCG +0.020, MRR +0.067 높아 라벨 정보를 임베딩에도 넣는 편이 유리했고, 가점 조정(+0.031)은 효과가 질의 2개에 집중되어 신뢰구간이 0을 포함한다.

7.2 질의 유형별 결과




그림 5에서 항상 폭은 부정 표현 질의가 가장 크다(0.173에서 0.893). 이는 임베딩이 부정 표현을 구분하지 못한다는 1.1절의 가정을 뒷받침하며, 극성 반전 규칙으로 부정을 필수 조건으로 바꾸는 것이 이 유형의 핵심이다. 기본(0.386에서 0.855)과 맥락(0.562에서 0.919)도 크게 올랐고, 메뉴 언급(0.793에서 0.794)은 메뉴 이름이 임베딩으로도 잘 잡히는 데다 "김밥이랑 국물"의 손실과 "샌드위치 가볍게"의 유지가 섞여 거의 변화가 없다. 판정 미확정 1개("안 매운 건 싫어")는 이중 부정을 처리하지 못해 오히려 떨어졌다(1.000에서 0.597).

7.3 질의별 결과

그림 6. 질의별 nDCG@5 (최종 점수 오름차순)




그림 6에서 36개 중 17개 질의가 nDCG 1.0이며, 임베딩만으로 0점이던 질의 8개 중 7개가 0.89~1.0으로 올랐다 ("바삭하고 기름진 음식", "튀김 아닌 걸로 가볍게", "매운 거 싫어" 등). 회색 점이 보이지 않는 질의는 두 설정의 점수가 같으며, 전체 수치는 부록 B에 있다.

7.4 가점 분리 (RQ2)

그림 7. 가점 조합별 nDCG@5





그림 7은 (w_m, w_c) 격자에서의 nDCG@5다. $w_m = 0.3$ 일 때 $w_c = 0.15$ 에서는 0.878에서 0.867로 떨어지고 $w_c \leq 0.05$ 에서는 결과가 같으며, 격자 밖에서 따로 켜 $w_c = 0.064$ 와 0.1도 0.878로 같았다. $w_c = 0.1$ 은 따름정리 1의 경계로, 전(부침개)의 점수가 국물 요리와 정확히 같아져 유사도로 순서가 갈리며, 이 질의에서는 유사도가 더 높은 국물 요리가 앞서 역전이 일어나지 않았다. 역전은 "비 오는 날 얼큰한 국물"에서 칼국수(매운맛 불일치)와 김치전(국물 불일치)이 모두 $p = 2/3$ 으로 가점 0.15를 받아 $p = 1$ 인 해장국, 매운탕을 앞지른 $w_c = 0.15$ 에서만 나타났다. w_m 은 $w_p = 0.3$ 과 같을 때 최고이고, 0.5로 올리면 "김밥이랑 국물"에서 김밥이 국물을 밀어내 전체가 0.862로 내려가며, $w_m = 0$ (언급 무시)은 0.835로 언급 가점이 필요함을 보여 준다. 이 격자는 평가 질의로 직접 고른 것이므로 최적값 자체보다는 따름정리가 예측한 경계에서 성능이 바뀐다는 점에 의미가 있다.

7.5 cross-encoder 재정렬 (RQ3)

그림 8. cross-encoder(bge-reranker-v2-m3) 재정렬 비교



필터 통과 후보의 $s(q, d)$ 를 bge-reranker-v2-m3의 관련도 $s_{CE}(q, d) \in [0, 1]$ 로 바꾸고 나머지 식은 그대로 두었다.

$$\text{score}_{CE}(q, d) = w_s \cdot s_{CE}(q, d) + w_p \cdot p(q, d) + b(q, d)$$

메뉴 텍스트는 라벨 나열, 이름만, 자연문장 세 가지를 시험했고, CE가 새로 올린 항목 368건은 같은 기준으로 추가 판정해 미판정 0%에서 비교했다. 이 실험은 승인 전 판정과 당시 코드로 측정했으므로 수치를 7.1절과 직접 비교하지 않는다.

- CE 단독(0.582)은 e5 단독(0.502)보다 높음
- 조건 로직과 합친 가장 좋은 조합도 0.772로 e5 기반 파이프라인(0.812)보다 낮음
- 한국어 음식 의미를 잘 모름 ("바삭하고 기름진 음식"에 떡찜·감자탕, "상큼하고 시원한 음식"에 매운탕)
- 글자 표면에 끌림 ("무조건 안 매운"에 무국, "김밥이랑 국물"에 김국)
- 메뉴를 직접 말한 질의("샌드위치 가볍게")에서만 강함

s_{CE} 는 $[0, 1]$ 전체에 퍼져 있어 명제 1의 조건 $w_s \Delta_s < w_p / |S|$ 가 깨지고, 따라서 CE의 잘못된 판단이 선호 조건을 이기며 순위를 흔든다. 그림 8과 같이 범용 다국어 재정렬 모델은 조건 로직이 이미 잡는 것 이상을 더하지 못해 채택하지 않았다.

7.6 대분류 우선 추천 (RQ3)

식품대분류를 먼저 고르고 그 안에서 메뉴를 추천하는 2단계 방식을 검토했다. 질의 q 의 적합 메뉴가 걸친 대분류 수를

$$\nu(q) = |\{\text{대분류}(d) : g(q, d) = 2\}|$$

로 정의하면, 대분류 하나만 고르는 방식이 얻을 수 있는 적합 메뉴는 많아야 가장 큰 대분류의 몫뿐이다.

그림 9. 질의별 정답의 대분류 분산




그림 9에서 $\nu(q) \geq 2$ 인 질의가 36개 중 23개이고("맵지 않고 따뜻한 음식"은 $\nu = 8$), $\nu(q) = 1$ 인 13개 질의("짬 요리", "매콤한 볶음" 등)는 현재 방식도 이미 해당 대분류 안에서 추천한다. 국밥이 밥류, 떡국이 면 및 만두류에 있는 것처럼 대분류 자체도 사용자의 음식 구분과 어긋나므로, 대분류는 순위 결정보다 결과를 묶어 보여 주거나 되묻는 화면 설계에 쓰는 것이 맞다.

7.7 오류 분석

질의	nDCG@5	원인
국물 없는 매운 음식	0.333	필수 국물=없음은 지켰지만 매운지 모호한 쟁반국수, 막국수(모두 1점)가 상위를 차지하고 제육볶음 같은 매운 비국물 요리가 유사도에서 밀림
단짠단짠한 음식	0.390	"단짠"은 스키마에 없는 맛이라 미처리로 남아 임베딩에만 의존, 찜뽕과 매운탕이 올라옴
안 매운 건 싫어	0.597	매운 것을 원한다는 이중 부정이 미처리로 남아 매운탕 2개 외에 미음, 묵밥이 섞임
뜨겁지 않은 음식	0.672	필수 제공온도는 지켰지만 "따뜻함"으로 라벨된 전류(1점)가 차가운 음식을 밀어냄
김밥이랑 국물	0.799	뒤쪽(국물)이 주인공인데 김밥에 언급 가점이 붙어 김밥 2개가 섞임

원인은 스키마에 없는 속성(단맛·신맛 등), 조건 추출기가 처리하지 못하는 이중 부정과 메뉴 조합 표현, 그리고 부분 적합 메뉴가 많은 조건에서 같은 선호 수준 안의 순서를 정하는 유사도의 약한 변별력(명제 1)의 세 가지로 모인다.

7.8 실행 시간

질의 임베딩을 포함해(모델 로딩 제외) 질의당 평균 13 ms, 최대 16 ms였다. 후보가 1,088건이라 전체 코사인 계산은 $O(|\mathcal{D}| \cdot 768)$ 로 무시할 만하며, 대부분의 시간은 질의 인코딩에 쓰인다.

8. 피드백 학습과 임베딩 미세조정 (RQ5)

추천 알고리즘을 웹 서비스(먹지)에 붙이면서 사용자 반응을 모으고, 이를 두 경로로 추천에 되돌리는 구조를 더했다. 하나는 모은 반응을 바로 점수에 반영하는 피드백 재랭킹이고, 다른 하나는 쌓인 반응과 승인 판정으로 인코더 자체를 다시 학습하는 미세조정이다.

8.1 서비스 연동

추천기는 메뉴를 고르고 음식점은 고르지 않는다. 서비스는 다음 순서로 메뉴를 주변 음식점으로 바꾼다.

1. 추천기가 상위 $3K$ 개 메뉴를 내고 대표식품명이 같은 메뉴를 하나로 합쳐 검색어 K 개를 만든다
2. 검색어마다 카카오 로컬 키워드 검색으로 반경 안의 음식점(분류 FD6)을 최대 15곳 찾는다
3. 메뉴의 계열(한식, 중식, 일식, 양식)과 음식점 대분류가 서로 다른 나라 음식이면 뺀다. 키워드 검색이 느슨해 "국밥"에 중식당이 걸리던 문제를 막는다
4. 카카오맵 가게 정보의 메뉴 목록에 검색어가 들어간 메뉴가 있는지 확인한다. 메뉴 목록이 있는데 검색어가 없으면 빼고, "라면사리"처럼 사리나 추가가 붙은 결들임은 인정하지 않는다
5. 음식점 일치도를 메뉴 점수와 거리로 매긴다

$$\text{match}(r) = 100 \cdot \left(0.8 \cdot \frac{\text{score}(q, m_r)}{\max_m \text{score}(q, m)} + 0.2 \cdot \left(1 - \frac{\min(\delta_r, R)}{R} \right) \right)$$

m_r 은 음식점 r 을 찾게 한 메뉴, δ_r 은 거리, R 은 검색 반경이다. 메뉴를 확인한 음식점을 먼저, 그다음 일치도와 거리 순으로 보여 준다. "라면"을 성공회대 정문 반경 1km로 검색했을 때 메뉴 확인을 거친 11곳은 모두 메뉴에 라면(라면, 떡라면, 계란라면 등)이 있었고, 그중 갈빗집 한 곳은 "라면사리"뿐이어서 결들임 규칙을 더했다.

8.2 피드백 수집과 즉시 재랭킹

추천 결과 화면의 "결과에 만족하시나요?", 음식점 상세의 "이 추천이 잘 맞았나요?"와 "이걸로 골랐어요!"로 (질의, 메뉴 검색어, 좋아요 여부)를 모은다. 질의 q 를 공백으로 나눈 단어 집합을 $T(q)$, 단어 t 와 메뉴 m 에 대한 좋아요와 별로예요 수를 $L_{t,m}$, $D_{t,m}$ 이라 하면 피드백 가점은

$$f(q, m) = w_f \cdot \frac{1}{|T(q)|} \sum_{t \in T(q)} \frac{L_{t,m} - D_{t,m}}{L_{t,m} + D_{t,m} + \alpha}, \quad w_f = 0.15, \alpha = 2$$

이고 "이걸로 골랐어요"는 좋아요 두 번으로 센다. 사전값 α 때문에 반응이 적으면 가점이 작고, $|f| < w_f$ 이다. 가점은 추천기가 필수 조건과 중복 제어를 거쳐 낸 상위 $3K$ 개에만 더하므로 필수 조건을 어기는 메뉴가 올라오는 일은 없다. w_f 는 언급 가점 $w_m = 0.3$ 의 절반이라 사용자가 이름을 말한 메뉴를 피드백만으로 밀어내지는 못하지만, 반응이 한쪽으로 충분히 쌓이면 선호 조건 한 단계($w_p/|S| \geq 0.1$, $|S| \leq 3$)는 넘을 수 있다. 따름정리 1이 약한 신호에 요구한 상한보다 크게 둔 것은, 피드백이 그 질의와 메뉴에 대한 직접 증거이기 때문이다.

"면 요리"에 냉면 좋아요 5번과 라면 별로예요 4번을 넣자 순위가 라면(0.905), 국수(0.900), 냉면(0.889)에서 냉면(0.997), 국수(0.900), 라면(0.805)으로 바뀌었다.

8.3 미세조정 방법

학습 데이터 승인 판정 중 적합도 2인 (질의, 메뉴) 쌍과 좋아요가 별로예요보다 많은 (질의, 메뉴 검색어) 쌍을 쓴다. 메뉴 쪽 입력은 임베딩을 만들 때 쓴 텍스트 B 원문이다. 평가 질의는 MD5 해시를 3으로 나눈 나머지가 0이면 평가용으로 두고 학습에서 뺀다. 판정이 있는 36개 질의 중 평가용은 10개, 학습용은 26개이며 학습 쌍은 295개다.

손실 배치 안의 다른 메뉴를 오답으로 쓰는 MultipleNegativesRankingLoss(Henderson et al., 2017)를 쓴다. 배치 크기를 B , 코사인 유사도를 sim , 온도를 $\tau = 0.05$ 라 하면

$$\mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(q_i, d_i)/\tau)}{\sum_{j=1}^B \exp(\text{sim}(q_i, d_j)/\tau)}$$

이다. 판정 데이터는 질의 하나에 적합 메뉴가 평균 11개라, 같은 질의나 같은 메뉴가 한 배치에 두 번 들면 서로의 정답이 오답 자리에 놓인다. 그래서 배치마다 질의와 메뉴가 겹치지 않게 나눈다. 기본 모델(multilingual-e5-base, 6.5절의 인코더)에서 시작해 $B = 16$, AdamW 학습률 2×10^{-5} 로 1에폭 학습하고, 후보 1,088개를 새 모델로 다시 인코딩한다. 노트북 CPU에서 학습, 재인코딩, 평가까지 한 번에 약 1분이다.


8.4 풀링 편향과 평가 지표

6.2절의 판정 풀은 기존 설정들의 상위 결과로 만들었으므로 기존 모델의 결과는 거의 모두 판정되어 있다. 미판정을 0점으로 두는 6.3절의 nDCG는 풀 밖의 메뉴를 내는 새 모델을 체계적으로 불리하게 만든다(Buckley & Voorhees, 2004). 실제로 기본 모델의 미판정 비율은 0%였지만 미세조정 모델은 32%(학습용), 23%(평가용)였다. 그래서 두 지표를 더 쓴다.

- **condensed nDCG@5**: 추천 상위 20개에서 미판정 항목을 지우고 남은 순서의 앞 5개로 nDCG를 잰다(Sakai, 2007)
- **정답 회수율@10**: 임베딩 검색 상위 10개에 든 적합도 2 메뉴의 비율, 분모는 $\min(10, |\{d : g(q, d) = 2\}|)$

모델 교체는 평가용 질의에서 condensed nDCG@5가 0.01 이상 오르고 정답 회수율@10이 떨어지지 않을 때만 한다.

8.5 결과



평가용 질의 10개

모델	nDCG@5 (미판정 0점)	미판정	condensed nDCG@5	정답 회수율@10
기본 모델	0.932	0%	0.932	0.439
미세조정 시드 0	0.751	26%	0.916	0.388
미세조정 시드 1	0.696	22%	0.892	0.408
미세조정 시드 2	0.773	22%	0.927	0.419
미세조정 평균	0.740	23%	0.911	0.405
중복 허용 배치 시드 0	0.701	26%	0.917	0.388

학습용 질의 26개

모델	nDCG@5 (미판정 0점)	미판정	condensed nDCG@5	정답 회수율@10
기본 모델	0.857	0%	0.857	0.405
미세조정 시드 0	0.645	32%	0.882	0.528
미세조정 시드 1	0.596	36%	0.847	0.450
미세조정 시드 2	0.732	27%	0.915	0.576
미세조정 평균	0.658	32%	0.881	0.518
중복 허용 배치 시드 0	0.678	31%	0.889	0.538

그림 10에서 미세조정은 학습용 질의의 정답 회수율을 0.405에서 0.518로, condensed nDCG를 0.857에서 0.881로 올렸다. 그러나 평가용 질의에서는 회수율이 0.439에서 0.405로, condensed nDCG가 0.932에서 0.911로 오히려 낮아졌다. 시드 0 기준 평가용 질의의 차이는 condensed nDCG -0.016 $[-0.092, +0.048]$, 회수율 -0.051 $[-0.171, +0.069]$ 로 둘 다 신뢰구간이 0을 포함한다. 학습에 쓴 질의의 정답을 외웠을 뿐 처음 보는 질의로는 일반화되지 않았으며, 서로 다른 질의 26개는 문장과 메뉴의 관계를 새로 배우기에 너무 적다. 교체 기준에 따라 서비스는 기본 모델을 유지했다.

미판정을 0점으로 둔 nDCG는 평가용에서 0.932에서 0.740으로 크게 떨어졌지만, 같은 모델의 condensed nDCG 차이는 -0.020 에 그쳐 하락의 대부분은 풀링 편향이다. 이 지표만 봤다면 미세조정이 추천을 크게 망친다고 잘못 결론 내렸을 것이며, 실제로 개발 중 첫 실험에서 이 하락을 배치 구성 탓으로 잘못 해석했다. 같은 시드로 비교하면 중복을 허용한 배치와 겹치지 않게 나눈 배치의 차이는 학습용 회수율 0.538 대 0.528, 평가용 0.388 대 0.388로 이 규모에서는 측정되지 않았다. 배치 분리는 손실의 정의상 맞는 처리라 유지했지만 효과는 확인하지 못했다.

8.6 운영

피드백은 AI 서버의 SQLite 파일에 저장하고 도커 볼륨에 두어 재배포 후에도 유지한다. 서버는 하루에 한 번 별도 프로세스로 미세조정 조건을 확인하며, 좋아요 쌍이 지난 시도보다 200개 이상 늘었을 때만 판정 쌍과 합쳐 기본 모델에서 다시 학습하고, 8.4절의 기준을 넘으면 새 모델과 후보 벡터로 교체해 다시 불러온다. 학습은 서비스 프로세스와 분리되어 추천 응답을 막지 않는다.

9. 논의

조건 로직과 임베딩의 역할 분담 명제 1과 7.1절의 결과를 함께 보면, 이 시스템에서 임베딩은 순위를 정하는 주체라기보다 후보 100개를 고르는 1차 필터이자 같은 선호 수준 안의 동점 해소 수단이다. 순위의 큰 틀은 조건 추출과 라벨이 정하므로 성능의 상한은 라벨 품질과 규칙 커버리지에 달려 있으며, 이는 cross-encoder처럼 더 강한 유사도 모델로 바꾸는 것이 효과가 없었던 이유이기도 하다.

가중치 선택의 원리 따름정리 1과 2는 가중치를 평가 질의에 맞춰 격자 탐색하기 전에도 정할 수 있는 원리를 준다. 연상처럼 약한 신호는 $w_p/|S|_{\max}$ 보다 작게, 사용자가 이름을 말한 메뉴처럼 강한 신호는 w_p 와 같게 두면 되며, 이 원리는 평가 질의에 덜 의존하므로 과적합 위험이 격자 탐색보다 작다.

필수 조건을 완화하지 않는 선택 제약 기반 추천의 일반적인 접근과 달리 필수 조건을 완화하지 않고 부족하면 사유와 함께 적게 반환한다. "맵지 않은"이라고 한 사용자에게 매운 음식을 섞어 5개를 채우는 것보다 3개만 보여 주는 편이 신뢰를 지킨다고 보았다.

10. 한계

10.1 평가 질의 과적합

평가 질의 40개는 개발자가 만들었고 조건 추출 규칙, 가중치, 가점도 이 질의를 보면서 정했으므로, 0.878은 일반화 성능이 아닌 개발 세트 성능이며 조정에 쓰지 않은 질의로 따로 측정해야 한다.

10.2 조건 추출 커버리지

규칙에 없는 표현은 조건 없이 임베딩만으로 처리되어 임베딩 단독 수준(nDCG 0.51)에 가까워지며, 실제 사용자의 표현 분포는 평가 질의보다 넓을 것이다.

10.3 라벨과 판정의 신뢰도

- 음식 속성 라벨은 모두 모델 추정이며 사람이 표본을 검토해 정확도를 측정하지 않았음
- 판정은 두 모델의 합의를 바탕으로 하고 사람이 모든 행을 직접 검토하지는 않았으므로, 일치한 800여 행에 두 모델이 공유하는 편향이 남아 있을 수 있음
- 폴링 판정은 폴 밖의 좋은 메뉴를 놓칠 수 있어, 폴을 만든 설정과 다른 새 방법은 미판정 비율을 함께 봐야 함

10.4 데이터 공백

공공 데이터에는 실제로 자주 찾을 치킨, 피자, 샐러드, 버거가 거의 없어 현재는 관련 없는 메뉴를 추천하므로 "해당 메뉴 데이터 없음"을 알리는 처리가 필요하다.

10.5 표본 크기

질의 36개에서는 신뢰구간이 넓어 nDCG 0.03 수준의 차이는 구분할 수 없다. 미세조정 평가용 질의는 10개뿐이라 8.5절의 결론도 방향만 보여 준다.

10.6 피드백 학습

- 로그인 없이 한 사람이 같은 반응을 반복해 보낼 수 있으며, 가점 상한 w_f 와 미세조정 교체 기준이 피해를 제한할 뿐 막지는 못함
- 피드백 가점은 추천기가 낸 상위 $3K$ 개 안에서만 순서를 바꾸므로, 좋아요를 받았더라도 후보 밖의 메뉴를 끌어올리지 못함
- 좋아요는 음식점까지 본 뒤의 반응이라 메뉴 적합성과 음식점 만족이 섞여 있음
- 음식점 메뉴 확인은 공개되지 않은 카카오맵 가게 정보를 쓰므로 구조가 바뀌면 확인 없이 동작하도록 두었음

11. 결론

규칙 기반 조건 추출과 속성 라벨 재랭킹을 밀집 검색에 더하자 nDCG@5가 0.509에서 0.878로 올랐고(RQ1), 향상은 부정 표현 질의에서 가장 컸다. 점수 척도 분석으로 재랭킹이 선호 우선의 사전식 정렬로 동작함을 보이고 가점 크기의 상한 조건을 유도했으며, 실험 결과는 그 경계와 맞았다(RQ2). 기성 cross-encoder는 한국어 음식 의미를 잘 모르고 점수 척도가 넓어 선호 조건을 흔들었고, 대분류 우선 추천은 정답이 여러 대분류에 흩어지는 질의가 많아 맞지 않았다(RQ3). 판정 세트는 교차 판정 가중 $\kappa_w = 0.919$ 로 일관성은 높지만 같은 계열 모델의 합의라는 한계가 있다(RQ4). 판정 기반 미세조정은 학습한 질의에서만 나아지고 처음 보는 질의로는 일반화되지 않았으며, 기존 판정 풀은 새 모델을 체계적으로 불리하게 재므로 condensed nDCG와 정답 회수율로 따로 평가해야 했다(RQ5).

향후 과제 (우선순위 순)

1. **보류 질의 평가**: 개발에 쓰지 않은 실제 사용자 질의 20~30개로 일반화 성능 측정
2. **데이터 공백 응답**: 후보가 없는 메뉴 요청에 "데이터 없음" 명시
3. **미처리 질의 기록**: 조건을 하나도 못 뽑은 질의를 결과에 표시하고 모아 규칙 확장 순서 결정
4. **스키마 확장**: 단맛, 신맛, 짠맛, 고소함 축 추가 후 재라벨링
5. **라벨 검증**: 속성 라벨 표본을 사람이 검토해 정확도를 측정하고 든든함의 $\perp$ 비율(23%) 축소
6. **미세조정 데이터 확보**: 판정 질의 26개로는 일반화되지 않았으므로(8.5절) 서로 다른 실제 질의의 피드백을 수백 쌍 이상 모은 뒤 다시 학습하고, 판정 풀에 새 모델 결과를 추가 판정해 미판정 비율을 낮춤

참고문헌

- Buckley, C., & Voorhees, E. M. (2004). Retrieval evaluation with incomplete information. *Proceedings of SIGIR 2004*, 25–32.
- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). *BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. arXiv:2402.03216.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46.
- Felfernig, A., & Burke, R. (2008). Constraint-based recommender systems: technologies and research issues. *Proceedings of ICEC 2008*.

- Henderson, M., Al-Rfou, R., Strope, B., Sung, Y., Lukács, L., Guo, R., Kumar, S., Miklos, B., & Kurzweil, R. (2017). *Efficient Natural Language Response Suggestion for Smart Reply*. arXiv:1705.00652.
- Järvelin, K., & Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4), 422–446.
- Nogueira, R., & Cho, K. (2019). *Passage Re-ranking with BERT*. arXiv:1901.04085.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of EMNLP-IJCNLP 2019*, 3982–3992.
- Sakai, T. (2007). Alternatives to Bpref. *Proceedings of SIGIR 2007*, 71–78.
- Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 Text Embeddings: A Technical Report*. arXiv:2402.05672.
- 공공데이터포털, 식품 영양성분 데이터베이스. <https://www.data.go.kr>

부록 A. 재현 방법

```
source .venv/bin/activate
pytest                                # 단위 테스트 155개
python docs/make_figures.py           # 그림 1~9와 docs/figures/stats.json 재생성
python docs/finetune_experiment.py    # 그림 10과 docs/figures/finetune.json 재생성 (미세조정
5회, 약 5분)
python -m api.finetune --force         # 서비스와 같은 미세조정 한 번 실행, 교체 여부는
state/current.json
jupyter notebook notebooks/          # 01~07 단계별 실험
```

data/ 는 Git에서 제외되어 있어 원본 CSV와 임베딩, 판정 파일(data/processed/evaluation/judgments.csv)이 따로 있어야 하며, 그림 8은 되돌린 실험의 기록값을 그린다. 본문의 모든 수치는 docs/figures/stats.json 에 있다.

부록 B. 질의별 nDCG@5

질의	유형	임베딩만	최종	차이
꼭 국물 요리로	복합	1.000	1.000	+0.000
너무 맵지 않은 국물 요리	복합	1.000	1.000	+0.000
느끼하지 않은 담백한 음식	기본	0.446	1.000	+0.554
든든한 밥 한 끼	기본	0.744	1.000	+0.256
따뜻하고 든든한 국밥	복합	0.869	1.000	+0.131
따뜻한 국이나 찌개	기본	1.000	1.000	+0.000
맵지 않고 따뜻한 음식	기본	0.903	1.000	+0.097
무조건 안 매운 걸로	부정	0.384	1.000	+0.616
바삭하고 기름진 음식	기본	0.000	1.000	+1.000
안 맵고 국물 있는 면	복합	0.333	1.000	+0.667
찜 요리 든든하게	복합	0.815	1.000	+0.185
차가운 국물 요리	복합	0.071	1.000	+0.929
차가운 면 요리	복합	0.640	1.000	+0.360
추운 날 뜨끈한 국밥	맥락	0.000	1.000	+1.000
튀김 아닌 걸로 가볍게	부정	0.000	1.000	+1.000
포만감 있는 저녁밥	기본	0.676	1.000	+0.324
해장되는 얼큰한 국	맥락	0.887	1.000	+0.113
빠르게 먹을 수 있는 간식	기본	0.000	0.935	+0.935
느끼한 거 말고 얼큰한 거	부정	0.604	0.912	+0.308
비 오는 날 얼큰한 국물 먹고 싶어	기본	0.431	0.912	+0.482
샌드위치 가볍게	메뉴 언급	0.912	0.912	+0.000
상큼하고 시원한 음식	기본	0.000	0.903	+0.903
야식으로 가벼운 거	맥락	0.589	0.903	+0.314
국물 없는 담백한 거	부정	0.000	0.887	+0.887
매운 거 싫어	부정	0.000	0.887	+0.887
김밥이랑 국물	메뉴 언급	0.799	0.799	+0.000
차갑고 가볍게 먹을 메뉴	기본	0.044	0.790	+0.746
비 오는 날 전 부쳐 먹고 싶다	맥락	0.774	0.774	+0.000
구운 고기 요리	복합	0.726	0.770	+0.044
떡볶이 매운 거	메뉴 언급	0.770	0.760	-0.010

질의	유형	임베딩만	최종	차이
매콤한 볶음 요리	복합	0.770	0.760	-0.010
피자 말고 버거	메뉴 언급	0.689	0.702	+0.013
뜨겁지 않은 음식	부정	0.049	0.672	+0.624
안 매운 건 싫어	미확정	1.000	0.597	-0.403
단짠단짠한 음식	기본	0.390	0.390	+0.000
국물 없는 매운 음식	기본	0.000	0.333	+0.333